

MATERIAL DE APOYO AL CICLO DE METODOLOGÍA I MÉTODOS CUANTITATIVOS

Repaso de conceptos del Ciclo Introductorio: Variables, medidas de tendencia central y de dispersión. Conceptos básicos de Probabilidad. Dra. Mariela Garau, AE Anaulina Silveira, Dra. Cecilia Kadessian

Prevalencia de anemia en niños de 6 a 24 meses de edad de tres centros de salud de la ciudad de La Paz

Cinthya Urquidí B ¹, Claudia Vera A ², Nohemi Trujillo B ³, Héctor Mejía S ⁴

Resumen

Objetivo: determinar la prevalencia de anemia en tres centros de salud. **Diseño:** estudio descriptivo.
Métodos: 114 niños de 6 a 24 meses de edad ingresaron al estudio, concurrentes a tres centros de salud de la ciudad de La Paz, dependientes del Ministerio de Salud. Se midieron los niveles en sangre capilar con técnicas y personal estandarizado, muestras que fueron procesadas inmediatamente con el sistema fotómetro portable HemoCue. Para el diagnóstico de anemia se utilizó un punto de corte ajustado para la altura de 13,6 g/dl.
Resultados: la prevalencia de anemia en los tres centros de Salud fue del 36,6%. En el centro de Bella Vista se registró un 8% de anemia severa, 10% de anemia moderada y 19% de leve. En Chasquipampa, 6% de anemia severa, 11% y 12% de anemia moderada y leve, respectivamente. En Villa Nuevo Potosí, 4% de severa, 9% de moderada y 20% de anemia leve. El índice de correlación de Spearman entre el indicador "talla para la edad" y niveles de hemoglobina fue de 0,2 ($p = 0,048$).
Conclusiones: existe una alta prevalencia de anemia en niños menores de 2 años, independientemente del género, estado nutricional o centro de salud al que asisten. Aunque la causa de anemia es multifactorial, la alta prevalencia es sugerente de que diversos programas implementados para su control no han sido del todo efectivos.

Summary

Objective: to determine the prevalence of anemia in children from three health centers of La Paz city. **Design:** Descriptive study.
Methods: 114 children with ages between 6 to 24 months were enrolled. Capillary blood samples were obtained from a finger Prick with the use of aseptic standardized techniques; hemoglobin concentrations were measured immediately with a portable HemoCue. A cut off point adjusted for altitude was determinate for diagnosis (13.6 g/dl).
Results: the prevalence of anemia in all of the health centres was 36.6%. In Bella Vista there was an 8% severe anemia, 10% moderate anemia and 19% of mild anemia. In Chasquipampa 6% severe anemia, 11% and 12% moderate anemia and mild anemia respectively. In Villa Nuevo Potosí, 4% severe anemia, 9% moderate and 20% mild anemia. The Index of correlation of Spearman between the indicator tall for age and levels of hemoglobin was 0,2 ($p=0,048$).
Conclusions: the high prevalence of anemia in children smaller than 2 years old, independently of gender, nutritional status and health center which they attend. Although the anemia has many causes, this high prevalence is suggestive that the diverse programs implemented for its control have not been effective.

Al inicio de éste trabajo hemos incluido el resumen de un artículo de investigación de prevalencia en anemia. Puede observarse que lo primero que los investigadores nos indican es el objetivo de su estudio. Al momento en que el o los investigadores deciden que su estudio tendrá por objetivo "determinar la prevalencia de anemia en tres centros de salud"; debieron plantear el diseño del estudio a realizar y de la mano con ello, decidir que características de la población de niños será útil conocer con el fin de calcular esa prevalencia.

Esas características a las que nos referimos, que presentan diferencias en cada individuo estudiado y cuya investigación determinará cumplir con el objetivo fijado es lo que llamamos **variables**. En este estudio en concreto puede observarse que la variable fundamental es la *anemia*. Existirán diversas formas de referirnos a la anemia, por ejemplo la presencia o ausencia de la misma; el valor que toma la variable que define la anemia en el individuo (valor de hemoglobina en g/dl); o ser categorizada en niveles.

En el caso concreto del artículo mencionado, vemos en la sección resultados que los autores optaron por trabajar la variable en categorías: leve, moderada y severa. Por ello, a continuación trabajaremos con los conceptos fundamentales en relación a las variables; como definición, tipos, escalas y en el numeral 2 analizaremos algunas medidas que pueden utilizarse según la escala de medida utilizada.

1. Concepto de variable. Tipos de variables y escalas de medición.

Una **variable** es una característica que toma distintos valores en los elementos de una población o muestra; el peso, la estatura, la frecuencia respiratoria, la presencia o no de cianosis, son algunas variables biológicas de uso frecuente en medicina.

Una primera clasificación de las variables es en **cualitativas** y **cuantitativas**, las primeras describen cualidades, mientras que las segundas refieren la cantidad de un atributo. Entre las primeras están el género, el color de ojos, el grupo étnico, el estadio de una enfermedad; entre las segundas el peso, la estatura, la presión arterial, la frecuencia cardíaca.

Podemos clasificar a su vez a las **variables cuantitativas** en **discretas** y **continuas**. Una variable continua es aquella que potencialmente puede tomar cualquier valor en algún intervalo de los números reales; el conjunto de valores posibles es denso (entre dos valores siempre existe otro valor posible). El tiempo transcurrido desde el diagnóstico, el peso, la presión arterial, la concentración de sodio en suero sanguíneo (natremia), son algunos ejemplos de variables continuas.

Una variable discreta es una variable que sólo toma valores en puntos aislados, que por lo general correlacionamos con los naturales. Ejemplos de ello son: la cantidad de ocupantes de una vivienda, el número de episodios convulsivos que presentó un paciente epiléptico a lo largo del año.

En general, cualquier variable que corresponda a un conteo de individuos, será discreta puesto que no podemos contemplar una fracción de individuo, mientras que toda variable referida al tiempo, volumen o distancia es potencialmente continua ya que esas magnitudes son continuas.

Por otra parte existen distintas escalas de medida: nominal, ordinal, de intervalo y de razón. La **escala nominal** simplemente nombra cada uno de los valores que toma la variable. Si una variable medida en escala nominal presenta valores numéricos, éstos tienen el mero sentido del símbolo y no puede operarse con ellos pues no representan una magnitud. Lo único que representa la escala nominal es una equivalencia, por lo que el único término pertinente para comparar valores de la variable es “igual a” (o “distinto de”). Esta escala se utiliza para variables cualitativas.

La **escala ordinal** se utiliza para algunas variables cualitativas, cuyos valores son susceptibles de ser ordenados. El valor numérico que se le da a cada clase no corresponde a una cuantificación, sólo a un ordenamiento, por ejemplo en la clasificación en clases sociales, los estadios de un cáncer, el grado de satisfacción del paciente con los cuidados prestados en un servicio de salud. Proporciona mayor información que la escala nominal ya que las comparaciones entre categorías pueden ser “igual a” (o “distinto de”) y “mayor que” (o “menor que”).

(1)Decimos “potencialmente” porque siempre estaremos limitados por la precisión del instrumento de medida: difícilmente encontremos a alguien que mida $\sqrt{2}$ metros ya que los valores que registraremos tendrán una precisión de centímetros, (por ej 1,42 metros).

La **escala de intervalo** se aplica a variables cuantitativas. Tiene la particularidad que una diferencia x entre dos valores tiene el mismo significado a lo largo de la escala: x unidades de medida. Se diferencia de la escala de razón por el hecho de no poseer cero absoluto. Un ejemplo de este tipo de escala son los grados Celsius para medir la temperatura. Con las variables medidas en escala de intervalo se pueden hacer las mismas comparaciones que con las variables en escala ordinal, pero además se pueden sumar y restar valores y por lo tanto calcular promedios.

Por último, **la escala de razón** agrega a las propiedades de la de intervalo el hecho de tener un cero absoluto, lo que redundo en que se puedan establecer proporciones, es decir que por ejemplo el valor 20 refiere exactamente al doble que el 10. Un ejemplo en contraposición con la escala de intervalo es la medición de la temperatura en grados Kelvin. Todas las operaciones entre reales tienen sentido cuando una variable es medida en escala de razón: sumar, restar, multiplicar y dividir.

Como cada tipo de variable y cada escala de medida reciben distinto tratamiento, es indispensable tener claro estos aspectos para la recolección y presentación de datos.

Ejemplos:

1.1) La variable presencia o ausencia de una enfermedad es un tipo de variable cualitativa y esta se mide en escala nominal, ya que los valores que toma la variable están nombrando. El sexo es otro tipo de variable cualitativa y se mide en escala nominal ya que los posibles valores que toma son femenino y masculino, a veces por razones de comodidad se puede adjudicar valores numéricos a los nombres de la variable cualitativa, pero sólo con un el objetivo de codificarlas como por ejemplo: 1 para sexo masculino y 2 para sexo femenino.

1.2) El numero de hijos, es un tipo de variable cuantitativa discreta , entre dos valores consecutivos no existe ningún valor posible, sería imposible tener por ejemplo dos hijos y medio. La escala que utilizamos para medirla es de razón ya que el cero nos habla de ausencia de la característica.

1.3) La edad es una variable cuantitativa continua, existen infinitos valores entre dos distintos, la escala utilizada es la de razón.

1.4) La temperatura en grados Celsius o la línea de tiempo con años antes de Cristo o después de Cristo son variables cuantitativas continuas medidas en escala de intervalo, ya que el cero en estos casos no indica la ausencia de la característica, teniendo cero grados Celsius sigue habiendo temperatura, y el año cero no quiere decir que no haya transcurrido ningún tiempo.

1.5) En el artículo citado, la anemia podría expresarse de distinta manera: si se decide trabajar con la hemoglobinemia, estaremos frente a una variable continua, medida en escala de razón, si consideramos simplemente la presencia o ausencia de anemia (lo que implica definir un punto de corte para la hemoglobinemia), estaremos frente a una variable cualitativa medida en escala nominal, y si tomamos tres categorías como se hizo efectivamente, se trata de una variable cualitativa medida en escala ordinal.

2. Un aspecto de la descripción estadística: gráficos

Para describir los datos se pueden realizar gráficos y tablas cuyo estudio se realizó en el Ciclo Introductorio. Recordaremos aquí algunas características generales.

Al construir un gráfico es fundamental tener claro qué tipo de variable estamos describiendo: el comportamiento de una variable cualitativa en escala nominal puede representarse mediante un gráfico de barras (fig 1) o un diagrama circular (Fig 2). Para representar la frecuencia de una variable cualitativa medida en escala ordinal o una variable cuantitativa discreta usamos diagrama de barras.

Una variable cuantitativa continua (o aún una variable cuantitativa discreta en la que se han creado categorías) se representa mediante un histograma (Fig 3), un polígono de densidad (Fig 3) o una ojiva de frecuencia acumulada (Fig 4).

Fig1: Causas de muerte en Uruguay 2008. Fuente: Ministerio de salud pública




Fig 2: Causas de muerte en Uruguay 2008. Fuente: Ministerio de salud pública




Fig.3. Edad de los entrevistados en una encuesta. Histograma y polígono de densidad.





Fig. 4. Gráfico de frecuencia acumulada de edad de los entrevistados en una encuesta.



Si se quiere representar dos variables cualitativas simultáneamente se pueden construir gráficos de barras pareadas (Fig 5) o barras apiladas (stacked) (Fig 6). Para representar una variable cuantitativa en función de los valores de una variable cualitativa se pueden construir polígonos de densidad “superpuestos” (Fig 7), ojivas (Fig 8) o gráficos de caja y bigote (boxplots) (Fig 9).

Por último, cuando nos interesa representar dos variables cuantitativas simultáneamente se usan diagramas de dispersión (Fig 10).

Fig 5. Presencia de conductas de riesgo para la transmisión de Enfermedades de Transmisión Sexual según el nivel de conocimientos.




Fig 6. Principales filos que componen la microbiota humana. Fuente: Bik EM Composition and function of the human-associated microbiota. Nutrition Reviews® Vol. 67(Suppl. 2)




Fig 7. Distribución por grupos de edad de la población del CCZ 9 y del resto de Montevideo. Fuente: INE. Censo 2011




Fig 8. Edad de aparición de cierta enfermedad en dos poblaciones




Fig 9. Construcción de un "boxplot" o gráfico de caja y bigote.





Fig 10. Presión arterial sistólica de 10 recién nacidos según edad gestacional.



3. Otro aspecto de la descripción estadística: medidas de resumen

Otra herramienta para la descripción de variables es el cálculo de medidas que resumen en uno o unos pocos números algunas características de la distribución de valores.

Se recogen datos referentes a un conjunto bien determinado de "individuos" u "objetos" que constituyen la **población** en estudio. En la medida que la población en estudio puede ser demasiado grande para ser abarcada por completo, (o aún puede ser potencial y no existir físicamente en un instante) se suele trabajar con un subconjunto de todas las observaciones posibles en la población, lo que constituye una **muestra**.

Una medida descriptiva relacionada con una variable aleatoria, cuando la variable se considera sobre toda la población se denomina "**parámetro**". No es posible obtener el valor exacto de un parámetro, a menos que sean estudiados todos los miembros de la población. Una medida descriptiva relacionada con una variable aleatoria, cuando la variable se considera sobre una muestra, se denomina "**estadístico**". Por convención se usan letras griegas para nombrar los parámetros y latinas para los estadísticos.

Los estadísticos tiene dos fines: describir la muestra que está disponible y servir de aproximación a los parámetros correspondientes. Los que calculemos variarán de muestra a muestra de una misma población, pero esperamos que sean buenos estimadores de los parámetros.

Las **medidas de resumen** pueden ser:

- de tendencia central
- de dispersión
- de posición.

Las primeras indican en torno a qué valor se distribuyen los datos, mientras que las medidas de dispersión, como lo indica su nombre, nos dan información acerca de cuanto se alejan los datos del valor central.

En la figura, los asteriscos representan datos. Vemos que los datos de A se distribuyen entorno al mismo valor que los de B: tendrán medidas de tendencia central similares; sin embargo, los datos de A están más agrupados entorno al valor central: tienen menor dispersión que los datos de B. Los datos C difieren de los anteriores en sus medidas de tendencia central, ya que se distribuyen entorno a un valor distinto; la medida de dispersión de estos datos será parecida a la de A. Por último, los datos D tienen medidas de tendencia central similares a las de C pero dispersión mayor.




Figura 1.

Medidas de tendencia central:

a) **La media:** Es la más utilizada de las medidas de resumen. Corresponde a la media aritmética o promedio de los datos, o sea que si $x_1, x_2, \dots, x_N$ son los valores que asume la variable X en una población de tamaño N , la media de la población (μ) se calcula:

$$\mu = \frac{\sum_{i=1}^{i=N} x_i}{N}$$

El estimador más preciso, consistente y no sesgado de la media de la población es la media de la muestra, que notamos $\bar{x}$ y para una muestra de tamaño n calculamos:

$$\bar{x} = \frac{\sum_{i=1}^{i=n} x_i}{n}$$

La media tiene las mismas unidades que las observaciones individuales, y se tomará, cuando corresponda, una cifra decimal más que las presentes en las observaciones. El uso de la media exige que la variable esté medida en escala de razón o de intervalo.

Si los datos están agrupados en intervalos de clase, la media se calculará tomando como valor representativo de la categoría el punto medio del intervalo (llamado “marca de clase”), que notaremos $\dot{x}$, multiplicado por la frecuencia absoluta de la categoría (cantidad de observaciones en esa categoría). Así, la fórmula para la media será:

$$\bar{x} = \frac{\sum_{i=1}^{i=k} \dot{x}_i \cdot f_i}{n}$$

donde k es el número de categorías que hemos creado, y f_i es la frecuencia absoluta de la i -ésima categoría.

Si trabajamos con frecuencias relativas, teniendo en cuenta que $\text{frec. relativa} = \text{frec. absoluta}/n$, la fórmula queda:

$$\bar{x} = \sum_{i=1}^{i=k} x_i \cdot \text{frel}_i$$

Ejemplo:

2.1) Los siguientes son los valores de glicemia en ayunas tomados de una muestra de 15 pacientes de una mutualista que no tienen diagnóstico de diabetes. Calcula la media, la mediana y el desvío estándar.

120, 105, 100, 96, 108, 110, 110, 123, 135, 145, 196, 208, 103, 89, 103

Cálculo de la media:

$$\bar{X} = \frac{120 + 105 + 100 + 96 + 108 + 110 + 110 + 123 + 135 + 145 + 196 + 208 + 103 + 89 + 103}{15}$$

$$\bar{X} = \frac{1851}{15} = 123,4$$

O también:

$$\bar{X} = \frac{120 + 105 + 100 + 96 + 108 + 110 \times 2 + 123 + 135 + 145 + 196 + 208 + 103 \times 2 + 89}{15} = 123,4$$

b) **La mediana:** Se define como el valor central en una serie ordenada de datos, es decir, que existen tantas observaciones mayores que la mediana como observaciones menores que ella. La mediana muestral es el mejor estimador de la mediana poblacional. Si la distribución es simétrica, la mediana es también un estimador insesgado de la media poblacional, pero no es un estimador preciso, y no debe usarse en lugar de $\bar{X}$.

La mediana de una muestra de tamaño n se obtiene, una vez ordenados los datos en forma creciente o decreciente, como la observación ubicada en la posición $\frac{n+1}{2}$ si n es impar, o el promedio de las observaciones ubicadas en las posiciones $\frac{n}{2}$ y $\frac{n}{2} + 1$ si el número de observaciones es par.

$$\left\{ \begin{array}{ll} \frac{x_{\frac{n+1}{2}}}{2} & \text{si } n \text{ impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2} & \text{si } n \text{ par} \end{array} \right.$$

2.2) En el **ejemplo** anterior: Como el número de observaciones es 15, el valor central está en la posición 8:

89 96 100 103 103 105 108 **110** 110 120 123 135 145 196 208

La mediana es 110

2.3) Supongamos que a los datos del ejemplo anterior se agrega una nueva observación: 103. Entonces la mediana será el promedio entre la observación 8 y la 9:

89 96 100 103 103 103 105 **108 110** 110 120 123 135 145 196 208

$$\text{Mediana} = \frac{108 + 110}{2} = 109$$

En caso de trabajar con datos agrupados, supondremos que la frecuencia tiene un comportamiento lineal dentro de cada intervalo y podremos interpolar. Una vez identificado el intervalo en el que se encuentra la observación $x_{\frac{n}{2}}$ tendremos:

$$Md = \liminf \text{ del intervalo} + \frac{\frac{n}{2} - \text{frec. acumulada hasta el comienzo del intervalo}}{N^\circ \text{ de observaciones en el intervalo}} \times \text{longitud del intervalo}$$

O, trabajando con frecuencia relativa:

$$Md = \liminf \text{ del intervalo} + \frac{0,5 - \text{frec. relativa acumulada hasta el intervalo}}{\text{frec relativa del intervalo}} \times \text{longitud del intervalo}$$

La mediana expresa menos información que la media en la medida en que no tiene en cuenta las observaciones individuales pero tiene como ventajas el no verse afectada por valores extremos que modifican grandemente a la media, se trata de un estadístico más "robusto" o "resistente". Además, la mediana se puede usar no sólo con datos en escala cardinal (razón o intervalo), sino también en escala ordinal.

c) **La moda:** Es el valor más frecuente en un conjunto de datos.

2.4) En el ejemplo 2.2: Existen dos modas: 103 y 110, valores que se repiten 2 veces. Esta distribución es bimodal.

2.5) En el ejemplo 2.3, la moda es 103, que se repite 3 veces.

Cuando los datos están agrupados en categorías, la clase que tiene la mayor **densidad de frecuencia** se denomina **clase modal** y la marca de clase de esta categoría es la moda.

Medidas de dispersión:

a) El rango: es la diferencia entre el mayor y el menor valor. Se puede calcular para escalas de razón o de intervalo. Como estimador del rango de la variable en la población, el rango muestral es sesgado e inexacto, ya que es muy poco probable que encontremos en la muestra el mayor y el menor valor de la población.

b) Varianza y desvío estándar: Para variables medidas en escala de intervalo o de razón interesará evaluar cuánto se alejan los datos de la media. Una forma es calcular la "distancia" de cada dato a la media como el valor absoluto de la diferencia y efectuar un promedio de estas distancias, esta es la llamada **desviación media** cuyas unidades coinciden con las de la variable.

$$\text{Desviación media de una muestra} = \frac{\sum_{i=1}^{i=n} |x_i - \bar{x}|}{n}$$

Otra forma de evaluar la desviación desde la media consiste en considerar el cuadrado de las diferencias (con lo que también eliminamos el problema de las diferencias negativas). La varianza, se define como la media de las diferencias cuadráticas de n observaciones con respecto a su media aritmética. Así calcularemos la **varianza poblacional**:

$$\sigma^2 = \frac{\sum_{i=1}^{i=N} (x_i - \mu)^2}{N}$$

En el caso de una muestra obtenemos el estadístico insesgado:

$$s^2 = \frac{\sum_{i=1}^{i=n} (x_i - \bar{x})^2}{n-1}$$

Si los datos están agrupados en categorías tomaremos la marca de clase como valor representativo de la misma, multiplicando por la frecuencia absoluta de la categoría:

$$s^2 = \frac{\sum_{i=1}^{i=k} (\bar{x}_i - \bar{x})^2 \cdot f_i}{n-1}$$

Las unidades de la varianza son las de la variable al cuadrado. Su raíz cuadrada es llamada desvío estándar y cuenta con la ventaja de tener las mismas unidades que la variable en estudio.

2.6) En el ejemplo anterior, la varianza se calcula:

$$s^2 = \frac{(89 - 123,4)^2 + (96 - 123,4)^2 + (100 - 123,4)^2 + \dots + (208 - 123,4)^2}{14} = \frac{17289,6}{14} = 1234,97$$

Y el desvío estándar:

$$s = \sqrt{1234,97} = 35,14$$

c) El coeficiente de variación (CV) se define como el cociente entre el *desvío estándar* y la *media*.

$$cv(\%) = \frac{s}{\bar{x}} \times 100$$

Esta es una medida relativa de la variabilidad respecto a la media, expresa la variación como un porcentaje de la misma.

Un ejemplo de aplicación del CV en medicina es el ancho de la banda eritrocitaria o RDW (red cell distribution wide) que se informa en el hemograma. La variabilidad se expresa mediante el coeficiente de variación del volumen de los glóbulos rojos. Su valor normal se encuentra entre 11.5 y 14.5%, valores para los cuales la población de glóbulos rojos es homogénea en cuanto a su tamaño. Valores por encima de lo normal plantean una población de eritrocitos heterogénea (anisocitosis).

Esta es una medida de variabilidad que se puede aplicar únicamente a **variables medidas en escala de razón**.

d) Rango intercuartílico: Es la diferencia entre el cuartil 3 (percentil 75) y el cuartil 1 (percentil 25). También se utiliza el semi-rango intercuartílico. Es de utilidad cuando la distribución de los datos es asimétrica.

Medidas de posición:

Las medidas de posición dan más información acerca de la distribución de los datos (algunos textos refieren a ellas como “Otras Medidas de Dispersión”).

Los **cuantiles** (palabra derivada de “cuantos”) son los valores de la variable que determinan en el conjunto de datos, subconjuntos con la misma cantidad de observaciones. Los valores que dividen la distribución en 100 partes iguales se denominan **percentiles** y son ampliamente utilizados en medicina. Por ejemplo, el percentil 30 (P_{30}) es el valor de la variable que deja por debajo al 30% de las observaciones.

Los **cuartiles** (palabra derivada de “cuarto”) surgen de dividir la distribución en cuatro partes iguales (Q_1 , Q_2 , Q_3 , Q_4) y corresponden a los percentiles 25, 50, 75 y 100.

Los deciles se obtienen dividiendo la distribución en 10 partes iguales y se corresponden con percentiles múltiplos de 10. Por ejemplo, el decil 3 (D_3) es el percentil 30.

La mediana es igual al decil 5, al cuartil 2 y al percentil 50.

Conceptos básicos de probabilidad

Algunos hechos se rigen por leyes físicas, químicas o de otra naturaleza tal que permite predecir los resultados, por ejemplo, un objeto de cualquier masa partiendo de un estado inicial de reposo, y dejado caer al vacío desde una torre de altura h , llega siempre al suelo con la misma velocidad: $v = 2gh$. Cuando el hombre genera este tipo de situaciones y mide sus resultados, realiza un experimento determinístico.

Cuando en un experimento no se puede predecir el resultado final, hablamos de experimento aleatorio. Este es el caso cuando lanzamos un dado y observamos su resultado, pero también es el caso cuando analizamos situaciones en las que intervienen variables biológicas: no es posible predecir exactamente el valor de hemoglobina de un individuo aún teniendo en cuenta su talla y su peso, ni la glicemia del individuo 15 minutos después de beber 50cc de solución de glucosa al 10%, ni la presión arterial media hora después de recibir un fármaco antihipertensivo. Estos hechos, están regidos en mayor o menor medida por el azar, que trasciende la regulación y la homeostasis. Lo que es más, cuando el médico establece un diagnóstico, lo que dice en realidad es “en base a los hallazgos clínicos (y paraclínicos) es altamente probable que usted tenga la enfermedad X”. De todo lo anterior se desprende la importancia del estudio de la probabilidad en la formación del médico.

El enfoque clásico o “a priori” permite el cálculo de probabilidades previo a la ocurrencia del evento. Se basa en el conocimiento del espacio muestral Ω , conjunto de todos los resultados posibles de un experimento. Según la definición clásica o de Laplace, si todos los resultados del experimento son igualmente probables, entonces la probabilidad de que tenga lugar el suceso A se define como el cociente entre el número de casos favorables y el número de casos posibles.

$$P(A) = \frac{\text{Nº de casos favorables}}{\text{Nº de casos posibles}}$$

Una definición axiomática de probabilidad podría realizarse con los siguientes axiomas:

- 1) $P(A) \geq 0$
- 2) $P(A_1 \cup A_2 \cup A_3 \cup \dots) = P(A_1) + P(A_2) + P(A_3) \dots$ si $A_i \cap A_j = \emptyset \quad \forall i, j$ con $i \neq j$ (es decir que la probabilidad de la unión de una colección finita o infinita de sucesos mutuamente excluyentes es igual a la suma de las probabilidades de todos los sucesos)
- 3) $P(\Omega) = 1$

Propiedades:

- a) $P(A^c) = 1 - P(A)$
- b) Si $A_1 \subseteq A_2$ entonces $P(A_1) \leq P(A_2)$
- c) $P(\emptyset) = 0$
- d) $P(A) \leq 1$
- e) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (Regla de la adición)

Dónde A^c representa el suceso complementario de A , es decir el formado por todos los resultados que no están en A .

Ejemplo:

3.1) La probabilidad de que un estudiante del primer año de la carrera de medicina sea varón es 0,38 ¿Cuál es la probabilidad de que un estudiante de año de la carrera de medicina sea mujer?

$$P(\text{Mujer})=1-P(\text{Varón})=0,72$$

Ejemplo:

3.2) El 40% de los pacientes que consultaron en una policlínica eran asmáticos (A). El 20% de los pacientes tenían como síntoma de reflujo gastroesofágico, pirosis (P). El 43% de los pacientes tenían alguna de las dos patologías. Calcular la probabilidad de que un paciente tomado al azar sufra de asma y de pirosis.

$$P(\text{Asma})=0.4$$

$$P(\text{pirosis})=0.2$$

$$P(\text{Asma} \cup \text{Pirosis})=0.43$$

$$P(\text{Asma} \cap \text{Pirosis})=?$$

$$P(\text{Asma} \cup \text{Pirosis})=P(\text{Asma})+P(\text{Pirosis})-P(\text{Asma} \cap \text{Pirosis})$$

$$\text{Despejando: } P(\text{Asma} \cap \text{Pirosis})=P(\text{Asma})+P(\text{Pirosis})-P(\text{Asma} \cup \text{Pirosis})$$

$$P(\text{Asma} \cap \text{Pirosis}) = 0.4 + 0.2 - 0.43 = 0.17$$

Probabilidad condicional e independencia.

La probabilidad de que ocurra el suceso A si ha ocurrido el suceso B se denomina probabilidad condicionada y se define:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

Obsérvese que según la definición de probabilidad condicionada, se puede escribir la probabilidad de la intersección de dos sucesos de probabilidad no nula como:

$$P(A \cap B) = P(B).P(A | B) \quad \text{o} \quad P(A \cap B) = P(A).P(B | A)$$

O sea, la probabilidad de la intersección de dos sucesos, es la probabilidad de uno cualquiera de ellos, multiplicada por la probabilidad del segundo sabiendo que ha ocurrido el primero. Si entre dos sucesos no existe ninguna relación cabe esperar que la expresión “sabiendo que” no aporte ninguna información. De este modo introducimos el concepto de independencia de dos sucesos A y B como:

$$A \text{ y } B \text{ son sucesos independientes} \Leftrightarrow P(A \cap B) = P(A).P(B)$$

lo que es equivalente a plantear:

$$\text{Si } P(A) \neq 0, A \text{ y } B \text{ son sucesos independientes} \Leftrightarrow P(B|A)=P(B)$$

$$\text{o si } P(B) \neq 0, A \text{ y } B \text{ son sucesos independientes} \Leftrightarrow P(A|B)=P(A).$$

Ejemplo

3.3) De acuerdo con los datos del ejemplo 3.2),

a) La presencia de asma y de reflujo ¿son sucesos independientes?

$$\text{Por } 3.2 \quad P(\text{Asma} \cap \text{Pirosis})= 0.17$$

además $P(\text{Asma}) \times P(\text{Pirosis}) = 0.4 \times 0.2 = 0.08$

Como $P(\text{Asma} \cap \text{Pirosis}) \neq P(\text{Asma}) \times P(\text{Pirosis})$, deducimos que no son sucesos independientes⁽²⁾

b) Calcular la probabilidad de que un paciente asmático presente pirosis.

$$P(\text{Pirosis}|\text{Asma}) = P(\text{Asma} \cap \text{Pirosis})/P(\text{Asma}) = 0.17/0.4 = 0.425$$

Muestreo con reposición y muestreo sin reposición:

Cuando nuestro objetivo es calcular una probabilidad a partir de un experimento en el que nuestro universo es finito y los sucesos son independientes, la probabilidad de la intersección puede calcularse (de acuerdo a lo expuesto anteriormente como el producto de las probabilidades de los sucesos). Para poder calcular esas probabilidades individuales debemos tener en cuenta de qué manera se obtienen los elementos: si son fruto de un muestreo con repetición o sin repetición.

En un **muestreo con reposición** las unidades se extraen una a una de la población, reemplazando la unidad seleccionada en cualquier extracción particular antes de realizar la siguiente extracción. Como la constitución de la población permanece inalterable en cada extracción, algunas unidades en el muestreo con reemplazo podrían seleccionarse más de una vez en la muestra. La probabilidad de cada unidad, de ser seleccionada permanece incambiada a cada extracción.

En un muestreo **sin reposición**, las unidades se extraen una a una de la población, y la unidad seleccionada en cualquier extracción no se devuelve a la población antes de seleccionar una unidad en la siguiente extracción. Obviamente, ninguna unidad se selecciona más de una vez en el muestreo sin reemplazo. La probabilidad de cada unidad de ser seleccionada se modifica (aumenta) en cada extracción.

Por **ejemplo**:

En una policlínica barrial se atienden 40 ancianos mayores de 80 años. Sabemos que 10 mayores de 80 años son diabéticos. Si se elige una muestra aleatoria de 3 pacientes mayores de 80 años ¿Cuál es la probabilidad de que los tres sean diabéticos?

La respuesta a esta pregunta depende de cómo se seleccionen los pacientes:

- si se realiza un muestreo con reposición (por ejemplo, se saca al azar la ficha de un paciente, se devuelve al fichero, luego se saca una segunda ficha, y así sucesivamente) la probabilidad será:

$$P(3\text{diabéticos}) = P(1^\circ\text{diabético} \cap 2^\circ\text{diabético} \cap 3^\circ\text{diabético})$$

como los sucesos son independientes :

$$P(3\text{diabéticos}) = P(1^\circ\text{diabético}) \times P(2^\circ\text{diabético}) \times P(3^\circ\text{diabético})$$

$$\text{Como } P(\text{diabético}) = \frac{\text{casos favorables}}{\text{casos posibles}}$$

$$P(3\text{diabéticos}) = \frac{10}{40} \times \frac{10}{40} \times \frac{10}{40} = \frac{1}{64} = 0.015$$

- si se realiza un muestreo sin reposición, la probabilidad de éxito variará a cada extracción:

$$P(3^{\text{º}} \text{diabético}) = P(1^{\text{º}} \text{diabético}) \times P(2^{\text{º}} \text{diabético}) \times P(3^{\text{º}} \text{diabético})$$

$$P(3^{\text{º}} \text{diabético}) = \frac{10}{40} \times \frac{9}{39} \times \frac{8}{38} = \frac{720}{59280} = 0.012$$

Si la cantidad de individuos es grande, la diferencia en las probabilidades obtenidas por ambos métodos de muestreo es muy pequeña, pero debe ponerse atención en esta diferencia si universo es pequeño. Un caso particular de probabilidad asociada a muestreo con reposición es la distribución binomial, que veremos en el capítulo siguiente.

A veces la probabilidad de un suceso se *estima* por la frecuencia relativa. Por ejemplo, una manera de aproximarnos a la probabilidad de que una intervención quirúrgica arriesgada tenga éxito es consultar el registro de las intervenciones quirúrgicas realizadas sobre pacientes similares, si de las últimas 10, ha sido un éxito en 8, la frecuencia relativa es $8/10=0,8$ se parecerá a esa probabilidad. La frecuencia relativa cambia, en el ejemplo anterior si el registro, en lugar de 10 pacientes, tuviera 11, la frecuencia relativa sería necesariamente distinta ($8/11$ ó $9/11$), pero hay una ley empírica que establece que cuando el "número de ensayos" (pacientes, en el ejemplo) es suficientemente grande, la frecuencia relativa se estabiliza. A veces, se define la probabilidad como el límite de la frecuencia relativa. Esto es conocido como "**enfoque de la probabilidad como frecuencia relativa**". (Ejemplo tomado del material de bioestadística del Hospital Ramón y Cajal).

El gráfico 1, tomado de Armitage, muestra cómo se comporta la proporción de "caras" obtenidas al tirar una moneda, a medida que aumenta el número de tiradas.





Fig. 3.1 Proportion of heads in a sequence of tosses of a coin with a logarithmic scale for the number of tosses (reprinted from Cramér, 1946, by permission of the author and publishers).

El teorema de Bayes:

Un resultado relevante relacionado con la probabilidad condicionada es el conocido como teorema de Bayes, que explicaremos aquí para un caso particular. Si consideramos el suceso B y dos sucesos A1 y A2

(2) Más adelante veremos que esta deducción es relativa, ya que los valores podrían no ser exactamente iguales pero muy cercanos, para investigar este tema desde el punto de vista estadístico se utiliza el test de chi cuadrado.



Por la definición de probabilidad condicionada $P(A_1 | B) = \frac{P(A_1 \cap B)}{P(B)}$ (1)

Como $P(B | A_1) = \frac{P(A_1 \cap B)}{P(A_1)}$ entonces $P(A_1 \cap B) = P(B | A_1) \times P(A_1)$ (2)

Como $P(B) = P(A_1 \cap B) + P(A_2 \cap B)$, aplicando lo anterior $P(B) = P(B | A_1) \times P(A_1) + P(B | A_2) \times P(A_2)$ (3)

Sustituyendo (2) y (3) en (1)

$$P(A_1 | B) = \frac{P(B | A_1) \times P(A_1)}{P(B | A_1) \times P(A_1) + P(B | A_2) \times P(A_2)}$$

Ejemplo:

3.4) Con el objeto de diagnosticar la coleditiasis se usa ultrasonido. Tal técnica da resultado positivo al 91% de los pacientes que realmente tienen litiasis y da resultado negativo al 98% de los que no la tienen. En la población que nos ocupa, la probabilidad de coleditiasis es de 0,2. ¿Cuál es la probabilidad de que un individuo con ultrasonido positivo tenga coleditiasis?

Aquí el suceso B sería tener el ultrasonido positivo, y A1 y A2 que el tener y no tener coleditiasis respectivamente.

Estamos buscando: $P(\text{coleditiasis} | \text{ultrasonido} +)$

Sabemos que: $P(\text{coleditiasis}) = 0.2$

$P(\text{ultrasonido} + | \text{coleditiasis}) = 0.91$

$P(\text{ultrasonido} + | \text{no coleditiasis}) = 0.98$

Aplicando el Teorema de Bayes:

$$P(c | u+) = \frac{P(u+ | c).P(c)}{P(u+ | c).P(c) + P(u+ | \text{no } c).P(\text{no } c)}$$

$$P(c | u+) = \frac{0.91 \times 0.2}{0.91 \times 0.2 + 0.02 \times 0.8} = 0.9192$$

Bibliografía:

- 1- Zar J. Biostatistical Análisis. Tercera Ed. New Jersey: Prentice Hall, 1996.
- 2- Pagano M, Gauvreau K. Principles of biostatistics. Second Ed. Belmont, California: Duxbury Press; 2000.
- 3- Ketzoian C y cols. Estadística Médica. Conceptos y aplicaciones el inicio de la formación médica. Oficina del Libro: Montevideo, 2004
- 4- Material de bioestadística del Hospital Ramón y Cajal, disponible en:
http://www.hrc.es/investigacion/bioest/Probabilidad_1.html#P11
- 5- Armitage P, Berry G, Matthews J. Statistical Methods in Medical Research. Fourth Ed. Blackwell: Oxford, 2002.