

Conceptos sobre estimación de proporciones Fiorella Cavalleri

Si definimos X como una variable aleatoria que solo puede tomar dos valores posibles 1 y 0 donde 1 representa a quienes tienen la característica de interés y 0 a los que no la tienen, asignándole una probabilidad de p y $1-p$ a cada uno.

$$X \approx \text{Bernoulli}(p)$$

$$X = \begin{cases} 1 \rightarrow p \\ 0 \rightarrow 1-p \end{cases} \quad \begin{aligned} E(X) &= 1 \cdot p + 0 \cdot (1-p) = p \\ V(X) &= p \cdot (1-p) \end{aligned}$$

X por ejemplo podría ser la variable X ="Diabetes" donde vale 1 si tiene la enfermedad y 0 si no la tiene.

Si se define la variable Y ="cantidad de diabéticos en n pruebas" si cada individuo es independiente y la probabilidad de ser diabético es constante entonces:

$$Y = \sum_{i=1}^n X_i \approx \text{Binomial}(n, p)$$

Tal que:
$$\begin{aligned} E(Y) &= np \\ V(Y) &= np(1-p) \end{aligned}$$

Obsérvese que para determinada relación entre n y p es decir:

$np > 5$ y $n(1-p) > 5$ la distribución Binomial se aproxima a una distribución normal es decir:

$$Y \approx \text{aprox}N(\mu = np; \sigma^2 = np(1-p))$$

Si se define como parámetro de interés p que será una proporción poblacional, tal que se define proporción como un cociente en el que en el numerador están todos los casos con las características de interés y en el denominador la población (los que tienen la característica de interés y los que no). Ahora bien siguiendo con el ejemplo de los diabéticos la proporción de diabéticos será:

$$p = \frac{\text{total_de_diabéticos}}{\text{población_total(diabéticos_y_no_diabéticos)}}$$

Pero ocurre que este parámetro es desconocido y por tanto el interés se centra en poder estimarlo y para ello se debe definir un estimador:

$$\hat{p} = \frac{Y}{n} = \frac{\sum_{i=1}^n X_i}{n}$$

Por lo tanto tenemos definido un estimador para p que es una variable aleatoria Binomial sobre n .

Obsérvese que:

Conceptos sobre estimación de proporciones Fiorella Cavalleri

$$E(\hat{P}) = E\left(\frac{Y}{n}\right) = \frac{1}{n} E(Y) = \frac{1}{n} np = p$$
$$V(\hat{P}) = V\left(\frac{Y}{n}\right) = \frac{1}{n^2} V(Y) = \frac{1}{n^2} np(1-p) = \frac{p(1-p)}{n}$$

Puede demostrarse que $\hat{P}$ distribuye aproximadamente normal con los parámetros antes mencionados es decir:

$$\hat{P} \approx \text{aprox.} N(\mu = p; \sigma^2 = \frac{p(1-p)}{n})$$

Teniendo definido el estadístico para p, si se extrajera una muestra de tamaño n supongamos n=100 y de esos 100 a cada uno le preguntáramos si tiene diabetes y anotáramos 1 si tiene la enfermedad y 0 si no la tiene entonces podríamos realizar una estimación puntual para p (que es la proporción de diabéticos), supongamos que de los 100, 7 respondieron tener diabetes:

$$\hat{p} = \frac{\sum_{i=1}^{100} x_i}{100} = \frac{7}{100} = 0,07$$

Si ahora quisiéramos acompañar la estimación puntual para p con un intervalo de confianza entonces deberíamos preguntarnos por:

$$P(a < \hat{P} < b) = 1 - \alpha$$

Para poder resolver esta probabilidad primero debemos observar que el la variable aleatoria $\hat{P}$ distribuye aproximadamente como una Normal (si np>5 y n(1-p)>5) , si es válida la aproximación entonces:

$$\hat{P} \approx \text{aprox.} Normal(\mu = p; \sigma^2 = \frac{p(1-p)}{n})$$
$$\sigma = \sqrt{\frac{p(1-p)}{n}}$$

Como no conozco p entonces σ lo aproximo por:

$$\sigma = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Conceptos sobre estimación de proporciones Fiorella Cavalleri

Por tanto:

$$\frac{\hat{p} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \approx Z = N(\mu = 0; \sigma = 1)$$

Luego de algunas cuentas se llega a que un intervalo de confianza para p al $(1-\alpha)\%$ de confianza será de la forma:

$$\hat{p} \pm Z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$